保险复杂咨询语音 Agent

陈为 个人参赛

OPEN-JS-01 语音交互与智能体

架构选型与实测指标

复杂咨询的任务与验收目标

多问项与多轮补条件，都需要继续原咨询

目标	正式验收要求
KR1 响应时延	首响≤3秒，复杂完整回答≤10秒
KR2 自然打断	成功率≥95%，打断后上下文连贯
KR3 回答与来源	复杂咨询准确率≥90%，每条结论可追溯
KR4 条件化回答	按年龄、医保、病史等条件回答或追问
KR5 安全兜底	不确定时转人工，不编造结论

示例：先说“有医保”，播报中改为“没有医保”，保费和待办都应更新。

快慢协同的回答链路



主回答输入 完整责任证据包、已确认条件、咨询待办、完整已播历史

当前默认为完整证据一次生成，动态RAG召回仍待验收。

技术选型与取舍

选型	负责什么	选择理由与取舍
Qwen Flash	意图、条件、问项	并行小任务，超时有默认处理
DeepSeek Flash	主业务生成	单遍生成并决定后置人工，发布前检查
腾讯 ASR	实时识别	WebSocket逐句识别，持续接收PCM
Qwen 实时 TTS	回答音频	逐句合成，合成失败可降级
完整责任证据包	条款与费率上下文	保留前提，输入较长，动态检索待验证
FastAPI + WS	网页与观察接口	本地启动简便，尚无生产持久化

网页新增语音验证采用Qwen对照，正式主链路选型保留DeepSeek。

核心指标与当前达标状态

exp44完整批次，固定开发题与合成语音，单人非盲审

验收项	实测证据	判断
首响 / 完整回答	承接0.68–0.83秒 复杂T02播完45.59秒	首声样本达标 完整回答未达
复杂准确率	26/30 = 86.7% 自动回答21/25 = 84.0%	未达90%
逐条来源支持	结构138/138有效 语义支持132/138 = 95.7%	仍6条缺口
自然打断	停播20/20 附和误停2/9，回声误停1/8	整体验收未完成
安全兜底	必转人工12/13 请求保存21/21	漏转未清零

整体正确处理133/143 = 93.0%，包含合理追问和人工请求。

现场演示：持续语音与条件更正



1 开启一次语音

2 提问后继续聆听

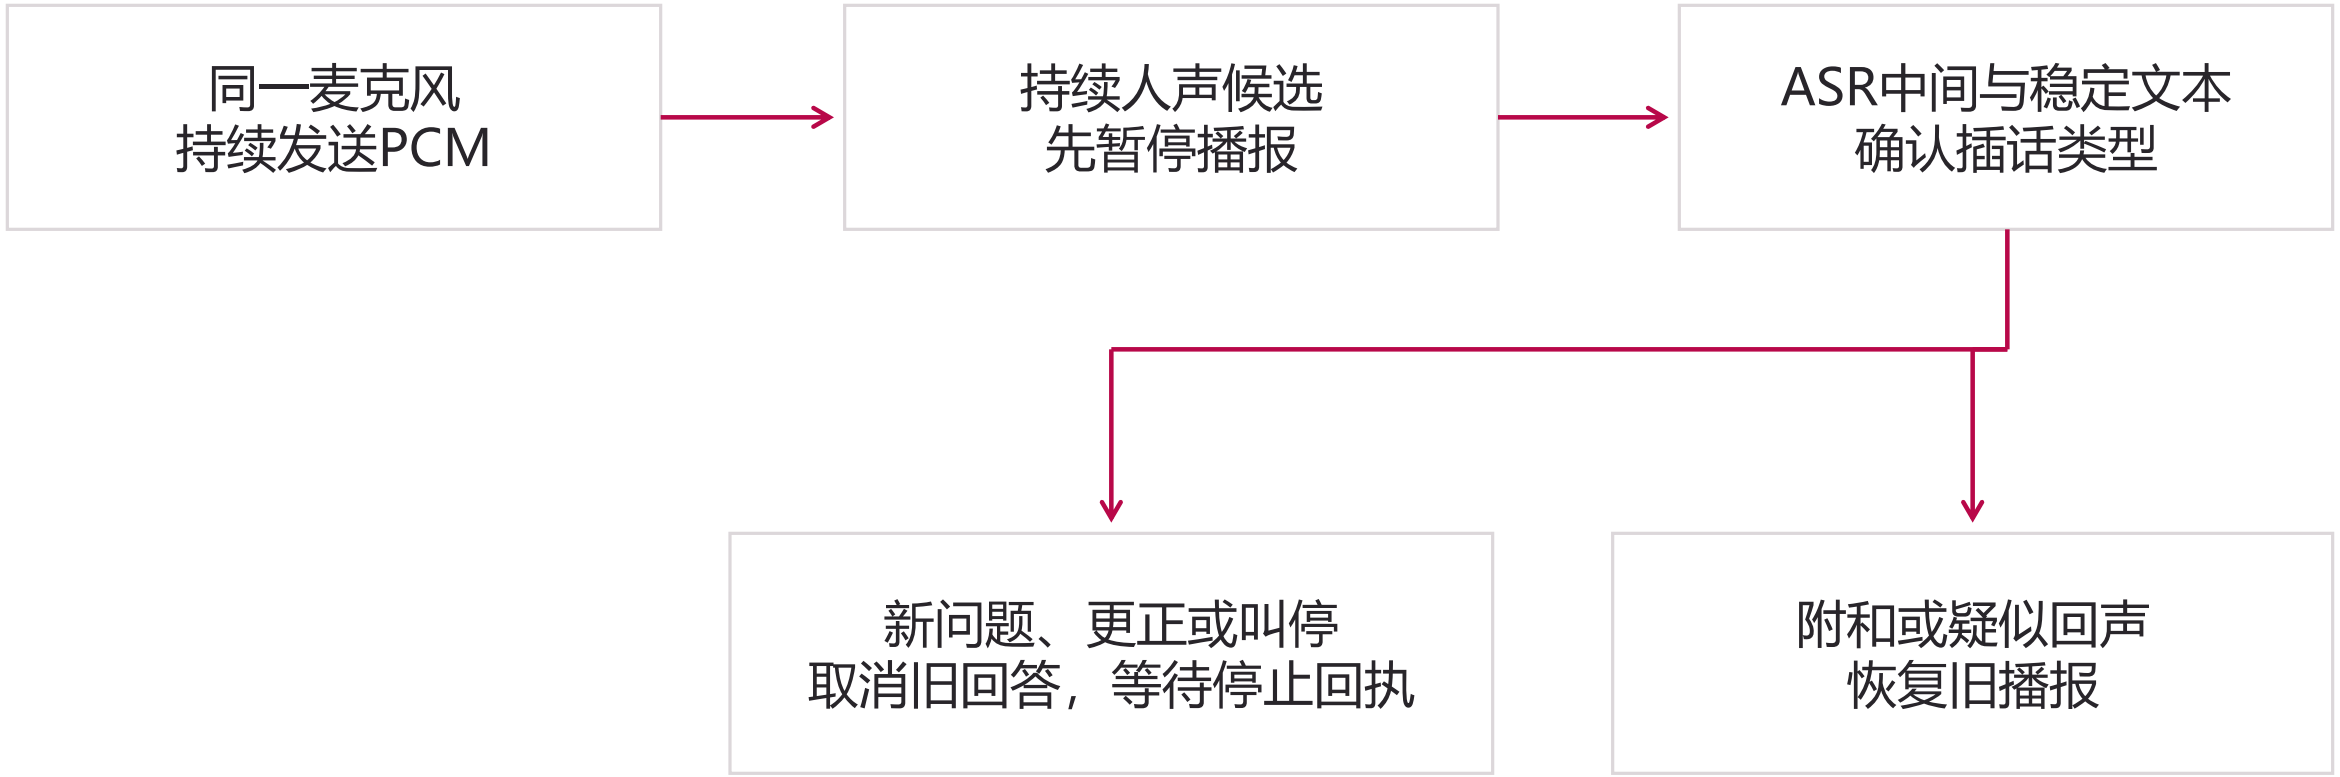
3 播报中更正医保

4 展开耗时与原文

http://127.0.0.1:8080

截图：Qwen对照，合成语音输入。前6页主讲结束，以下为答辩附录。

持续收音与插话处理



麦克风保持开启，结束语音时主动释放音轨。识别连接空闲续期。

插话后的生成记录与已播历史

真实ASR、模型与TTS，输入为合成MediaStream，Qwen对照

第一轮完整生成

35岁、有医保
年缴保费423元

正文未播完，记录标为取消

下一轮实际已播历史

“我帮您查一下。
您关心的保费，我一起核对。”

保留用户更正：没有医保
新答复：年缴971元

同一次开启麦克风跨两轮，旧未播金额没有进入已播历史。

完整责任证据与可追溯输出

材料	组织方式	回答核对
原始PDF条款	条款段落与定位索引	原文、页码与行号
保障责任表	责任组与完整所属上下文	免赔、比例、医院与人群
保费与优惠规则	年龄、医保、缴费等字段	适用范围与金额来源
会话条件和待办	用户原话与任务ID	已确认条件、缺条件追问

353项分组证据。来源结构有效，仍需要判断结论是否真正受原文支持。

准确率分母与错误分布

复杂子集与混合批次分别报告

分组	正确处理	比例	自动回答正确
C 复杂/复合	26/30	86.7%	21/25 = 84.0%
E 费用计算	40/40	100%	31/31
H 待办/追问	16/16	100%	7/7
Y 销售基础	35/41	85.4%	28/30
N 长尾	16/16	100%	15/15
总计	133/143	93.0%	102/108 = 94.4%

C12/C18/C19/C28未通过。Y003–Y006服务失败保留在总分母。

首声、正文与完整播完分别计时

计时点	exp44实际DAC	网页Qwen样本
首次承接出声	0.68–0.83秒	3.77秒
业务正文首声	6.36–8.83秒 正常T01–T05	24.06秒
整轮播放结束	复杂T02：45.59秒	34.84秒，原速

exp44起点为用户声学句尾，网页起点为已识别文本提交。
模型、样本与测量方法不同，两批数据不可直接作性能对比。

验收缺口与下一步验证

仍未完成	具体缺口	下一步
复杂准确率	C12/C18/C19/C28	修复后全30题及新留出题复验
完整回答≤10秒	复杂口播过长	保留必要条件，缩短正文并测播完
每条来源支持	仍6条语义或范围缺口	逐句审核原文与适用口径
自然打断	附和、回声与真人AEC	真人麦克风和外放场景验证
真实服务动作	人工漏转，接通/短信未集成	补漏转，验证真实接口回执

冻结版本与资料包复现

冻结核心	v0.1.0-core-20261014
网页演示版	v0.3.0-duplex-20261014
程序验证	143项Python测试，7项语音状态测试
离线复核	7轮原始回放，143题结果与审核 包内有校验清单，不含服务密钥

启动：python scripts/run_demo.py　打开：http://127.0.0.1:8080

评委问答准备

问题	回答要点
为什么用完整证据?	保留责任前提，减少漏检。规模扩大时需检索与召回验证。
为什么93%仍未达标?	混合批次与复杂子集分母不同，复杂26/30低于90%。
有引用为何还会错?	出处真实只验证结构，结论支持需要语义与条件审核。
三秒首响是什么?	当前样本包含固定承接，正文和播完独立统计。
打断后如何续聊?	已播句进入历史，未播答案只留审计，新条件重新处理。